

OPENCLASSROOMS

Parcours Data-Scientist – Projet 2



ANALYSEZ DES DONNÉES DE SYSTÈMES ÉDUCATIFS

PROBLÉMATIQUE SOMMAIRE

- Présentation des datasets
- Nettoyage des données
- Étude de l'expansion d'Academy
 - Infrastructures de communication
 - Enseignants
 - Etudes Secondaires
 - Etudes Tertiaires

Mission d'analyse exploratoire à partir des données de la banque mondiale :

- Quels sont les pays avec un fort potentiel de clients pour nos services?
- Pour chacun de ces pays, quelle sera l'évolution de ce potentiel de clients ?
- Dans quels pays l'entreprise doit-elle opérer en priorité?

Présentation des datasets:

- Structure
- Contenus

Pandas.info():

Structure des datasets

EdStatsCountry.csv

memory usage: 60.4+ KB

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 241 entries, 0 to 240
Data columns (total 32 columns):
Country Code
                                                      241 non-null object
Short Name
                                                      241 non-null object
Table Name
                                                      241 non-null object
Long Name
                                                      241 non-null object
2-alpha code
                                                      238 non-null object
Currency Unit
                                                      215 non-null object
Special Notes
                                                      145 non-null object
Region
                                                      214 non-null object
Income Group
                                                      214 non-null object
WB-2 code
                                                      240 non-null object
National accounts base year
                                                      205 non-null object
National accounts reference year
                                                      32 non-null float64
SNA price valuation
                                                      197 non-null object
                                                      144 non-null object
Lending category
                                                      58 non-null object
Other groups
System of National Accounts
                                                      215 non-null object
Alternative conversion factor
                                                      47 non-null object
PPP survey year
                                                      145 non-null object
Balance of Payments Manual in use
                                                      181 non-null object
External debt Reporting status
                                                      124 non-null object
System of trade
                                                      200 non-null object
Government Accounting concept
                                                      161 non-null object
IMF data dissemination standard
                                                      181 non-null object
Latest population census
                                                      213 non-null object
Latest household survey
                                                      141 non-null object
Source of most recent Income and expenditure data
                                                      160 non-null object
                                                      111 non-null object
Vital registration complete
Latest agricultural census
                                                      142 non-null object
Latest industrial data
                                                      107 non-null float64
Latest trade data
                                                      185 non-null float64
Latest water withdrawal data
                                                      179 non-null object
Unnamed: 31
                                                      0 non-null float64
dtypes: float64(4), object(28)
```

EdStatsCountry-Series.csv

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 613 entries, 0 to 612
Data columns (total 4 columns):
CountryCode 613 non-null object
SeriesCode 613 non-null object
DESCRIPTION 613 non-null object
Unnamed: 3 0 non-null float64
dtypes: float64(1), object(3)
memory usage: 19.3+ KB
```

EdStatsData.csv

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 886930 entries, 0 to 886929
Data columns (total 70 columns):
Country Name
                  886930 non-null object
Country Code
                  886930 non-null object
Indicator Name
                  886930 non-null object
Indicator Code
                  886930 non-null object
1970
                  72288 non-null float64
1971
                  35537 non-null float64
1972
                  35619 non-null float64
1973
                  35545 non-null float64
1974
                  35730 non-null float64
1975
                  87306 non-null float64
1976
                  37483 non-null float64
1977
                  37574 non-null float64
```

EdStatsSeries.csv

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 3665 entries, 0 to 3664
Data columns (total 21 columns):
Series Code
                                        3665 non-null object
Topic
                                        3665 non-null object
Indicator Name
                                        3665 non-null object
Short definition
                                        2156 non-null object
                                        3665 non-null object
Long definition
Unit of measure
                                        0 non-null float64
Periodicity
                                        99 non-null object
Base Period
                                        314 non-null object
Other notes
                                        552 non-null object
Aggregation method
                                        47 non-null object
                                        14 non-null object
Limitations and exceptions
Notes from original source
                                        0 non-null float64
General comments
                                        14 non-null object
Source
                                        3665 non-null object
Statistical concept and methodology
                                        23 non-null object
Development relevance
                                        3 non-null object
Related source links
                                        215 non-null object
Other web links
                                        0 non-null float64
                                        0 non-null float64
Related indicators
License Type
                                        0 non-null float64
Unnamed: 20
                                        0 non-null float64
dtypes: float64(6), object(15)
memory usage: 601.4+ KB
```

EdStatsFootNote.csv

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 643638 entries, 0 to 643637
Data columns (total 5 columns):
CountryCode 643638 non-null object
SeriesCode 643638 non-null object
Year 643638 non-null object
DESCRIPTION 643638 non-null object
Unnamed: 4 0 non-null float64
dtypes: float64(1), object(4)
memory usage: 24.6+ MB
```

241 non-null object

241 non-null object

241 non-null object

241 non-null object

238 non-null object

215 non-null object

145 non-null object

214 non-null object

214 non-null object

240 non-null object

205 non-null object

32 non-null float64

197 non-null object

144 non-null object

58 non-null object

215 non-null object

47 non-null object

145 non-null object

181 non-null object

124 non-null object

200 non-null object

161 non-null object

181 non-null object

213 non-null object

141 non-null object

160 non-null object

111 non-null object

142 non-null object

107 non-null float64

185 non-null float64

179 non-null object

0 non-null float64

Pandas.info():

Contenu des datasets



EdStatsCountry.csv

<class 'pandas.core.frame.DataFrame'>
RangeIndex: 241 entries, 0 to 240
Data columns (total 32 columns):
Country Code
Short Name
Table Name
Long Name

2-alpha code Currency Unit Special Notes

Region
Income Group
WB-2 code

National accounts base year National accounts reference year

SNA price valuation Lending category Other groups

System of National Accounts Alternative conversion factor

PPP survey year

Balance of Payments Manual in use External debt Reporting status

External debt R System of trade

Government Accounting concept

IMF data dissemination standard Latest population census

Latest household survey
Source of most recent Income and expenditure data

Vital registration complete Latest agricultural census

Latest industrial data Latest trade data

Latest water withdrawal data

Unnamed: 31

dtypes: float64(4), object(28)

memory usage: 60.4+ KB

EdStatsCountry-Series.csv

<class 'pandas.core.frame.DataFrame'>
RangeIndex: 613 entries, 0 to 612
Data columns (total 4 columns):
CountryCore 613 non-null object
SeriesCode REDONDANTnull object
DESCRIPTION 613 non-null object
Unnamed: 3 0 non-null float64
dtypes: float64(1), object(3)
memory usage: 19.3+ KB

EdStatsData.csv

<class 'pandas.core.frame.DataFrame'>
RangeIndex: 886930 entries, 0 to 886929
Data columns (total 70 columns):

gezee	
Data columns (total 70 columns):
Country Name	886930 non-null object
Country Code	886930 non-null object
Indicator Name	886930 non-null object
Indicator Code	886930 non-null object
1970	72288 non-null float64
1971	35537 non-null float64
1972	35619 non-null float64
1973	35545 non-null float64
1974	35730 non-null float64
1975	87306 non-null float64
1976	37483 non-null float64
1977	37574 non-null float64

EdStatsSeries.csv

<class 'pandas.core.frame.DataFrame'> RangeIndex: 3665 entries, 0 to 3664 Data columns (total 21 columns): Series Code Topic Indicator Name Short definition Long definition Unit of measure Periodicity Base Period Other notes Aggregation method Limitations and exceptions Notes from original source General comments Source Statistical concept and methodology Development relevance Related source links Other web links Related indicators License Type

Unnamed: 20 dtypes: float64(6), object(15) memory usage: 601.4+ KB

3665 non-null object 3665 non-null object 3665 non-null object 2156 non-null object 3665 non-null object 0 non-null float64 99 non-null object 314 non-null object 552 non-null object 47 non-null object 14 non-null object 0 non-null float64 14 non-null object 3665 non-null object 23 non-null object 3 non-null object 215 non-null object 0 non-null float64 0 non-null float64

0 non-null float64

0 non-null float64

EdStatsFootNote.csv

<class 'pandas.core.frame.DataFrame'>
RangeIndex: 643638 entries, 0 to 643637
Data columns (total 5 columns):
CountryCode 643638 non-null object
SeriesCode 643638 non-null object
Year REDONDANT null object
DESCRIPTICH 643638 non-null object
Unnamed: 4 0 non-null float64
dtypes: float64(1), object(4)
memory usage: 24.6+ MB

seaborn.barplot():

Contenu des datasets



EdStatsCountry.csv

<class 'pandas.core.frame.DataFrame'> RangeIndex: 241 entries, 0 to 240 Data columns (total 32 columns):

Country Code Short Name Table Name Long Name 2-alpha code

Currency Unit Special Notes Region

Income Group

WB-2 code National accounts base year National accounts reference year

SNA price valuation Lending category Other groups System of National Accounts Alternative conversion factor

PPP survey year Balance of Payments Manual in use

External debt Reporting status

System of trade

Government Accounting concept IMF data dissemination standard

Latest population census Latest household survey

Source of most recent Income and expenditure data

Vital registration complete Latest agricultural census

Latest industrial data

Latest trade data

Latest water withdrawal data

Unnamed: 31

dtypes: float64(4), object(28)

memory usage: 60.4+ KB

241 non-null object 241 non-null object 241 non-null object 241 non-null object 238 non-null object 215 non-null object 145 non-null object 214 non-null object 214 non-null object 240 non-null object 205 non-null object 32 non-null float64 197 non-null object 144 non-null object 58 non-null object 215 non-null object 47 non-null object 145 non-null object 181 non-null object 124 non-null object 200 non-null object 161 non-null object 181 non-null object 213 non-null object 141 non-null object 160 non-null object 111 non-null object 142 non-null object 107 non-null float64 185 non-null float64 179 non-null object 0 non-null float64



High income: nonOECD


seaborn.barplot():


EdStatsData.csv

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 886930 entries, 0 to 886929
Data columns (total 70 columns):
                  886930 non-null object
                  886930 non-null object
Country Code
Indicator Name
                  886930 non-null object
Indicator Code
                  886930 non-null object
1970
                  72288 non-null float64
1971
                  35537 non-null float64
1972
                  35619 non-null float64
1973
                  35545 non-null float64
1974
                  35730 non-null float64
1975
                  87306 non-null float64
1976
                  37483 non-null float64
1977
                  37574 non-null float64
```

Intéressant
Intéressant mais
redondant/manquant

Contenu des datasets





Contenu des datasets

seaborn.barplot():


EdStatsSeries.csv

<class 'pandas.core.frame.DataFrame'> RangeIndex: 3665 entries, 0 to 3664 Data columns (total 21 columns): Topic Indicator Name Short definition Long definition Unit of measure Periodicity Base Period Other notes Aggregation method Limitations and exceptions Notes from original source General comments Source Statistical concept and methodology Development relevance

Development relevance
Related source links
Other web links
Related indicators
License Type
Unnamed: 20
dtypes: float64(6), object(15

dtypes: float64(6), object(15)
memory usage: 601.4+ KB

3665 non-null object 3665 non-null object 3665 non-null object 2156 non-null object 3665 non-null object 0 non-null float64 99 non-null object 314 non-null object 552 non-null object 47 non-null object 14 non-null object 0 non-null float64 14 non-null object 3665 non-null object 23 non-null object 3 non-null object 215 non-null object 0 non-null float64 0 non-null float64 0 non-null float64 0 non-null float64






NETTOYAGE DES DONNÉES

Nettoyage des données :


- Edition des datasets
- Fusion
- Elimination des doublons
- Subdivision en groupes


NETTOYAGE DES DONNÉES



Infrastructures & communication:


- Ordinateurs personnels
- Utilisateurs d'Internet






- 2005 + : interruption des données
- Même tendance
- Am. Nord reste la plus équipée
- Ecart important entre Am.
 Nord et reste du Monde
- Asie du Sud la moins équipée

Infrastructures & communication





Le Top 5 avoisine les 100%

22.4%

Upper middle income

 Les pays riches sont 3x plus équipés que les pays pauvres


16.6%


Middle income

Enseignants:


- Evolution des enseignants dans le secondaire
- Evolution des enseignants dans le tertiaire


Enseignants













- La Chine domine le Secondaire
- L'Inde domine le Tertiaire

Etudes Secondaires:


- Inscriptions dans le secondaire
- Ecoles privées
- Redoublements
- Durées d'études

Etudes Secondaires







- Plusieurs pays ne renseignent qu'en périodes précises (recensement ?)
- 2015: L'Asie atteint 160 M d'inscriptions
- Stagnation de l'Europe & Am.
 Latine
- Chine : apogée en 2007 puis baisse
- Inde : augmentation constante




- Les pays à moyens revenus dominent
- Les pays à hauts revenus stagnent à 50 M d'inscrits


Etudes Secondaires









- Asie du Sud domine largement (~50% en 2015)
- Même tendance du Top 5
- Moyen Orient / Afrique du Nord / Monde Arabe : fréquentent le moins les établissements privés







- L'ensemble des pays aux revenus moyens / moyen / fréquentent le plus les établissements secondaires privés
- Les pays à revenus moyens dominent largement les autres groupes (35% en 2000, 40% en 2015)
- Les pays riches ne dépassent pas les 20%

Etudes Secondaires







- Le plus faible = le meilleur
- ¼ de redoublants dans les pays du Top 5
- La Corée du Sud obtient le meilleur taux (quasi nul) de redoublants dans le secondaire



- La durée de scolarité dans le secondaire est de 9 ans en Allemagne (stable)
- Chute en Australie en 2005 (~ -1,5 an)







- GPI:
 - > 1 : domination féminine
 - = 1 : parité
 - < 1 : domination masculine</p>
- Botswana & Tanzanie : les redoublants sont en majorité des femmes
- Moldavie & Vietnam : les redoublants sont en majorité des hommes

Etudes Tertiaires:


- Inscriptions dans le Tertiaire
- Ecoles privées
- Programmes
- Durées d'études







- 2015 : L'Asie de l'Est atteint 70 M d'inscriptions
- Afrique Sub-Saharienne suit la tendance tout en enregistrant le moins d'inscriptions

Etudes Tertiaires





- Plusieurs pays ne renseignent qu'en périodes précises (recensement ?)
- 2003 : la Chine domine le reste du Monde
- L'Inde suit la même tendance, passe numéro 2 dès 2010
- Les pays à moyens revenus ont le plus d'étudiants inscrits dans le Tertiaire




- 3 pays indiquent 100%
- Lettonie & Estonie avoisinent les 100%


Etudes Tertiaires




- Disparités dans les programmes d'Education / Sciences humaines & Art / Agriculture / Santé / Services
- Les Sciences Sociales / Economie / Droit atteignent jusqu'à 46% d'inscrits dans le Tertiaire

Etudes Tertiaires






- 2015: 4,5 ans en Am. Du Nord, suivi par l'EU (3 ans)
- Corée du Sud & USA sont les plus longs
- Déclin des US à partir de 2011




- GPI:
 - > 1 : domination féminine
 - = 1 : parité
 - < 1 : domination masculine
- Amérique : écoles supérieures terminées majoritairement par des femmes



GPI:


- > 1 : domination féminine
- = 1 : parité
- < 1 : domination masculine
- Afrique Sub-Saharienne
 & Asie du Sud : écoles
 supérieures
 majoritairement
 terminées par des
 hommes






GPI:

- > 1 : domination féminine
- = 1 : parité
- < 1 : domination masculine
- Qatar & Top 5 : écoles supérieures très majoritairement terminées par des femmes
- Chad & Afghanistan : écoles supérieures très majoritairement terminées par des hommes





- GPI:
 - > 1 : domination féminine
 - = 1 : parité
 - < 1 : domination masculine
- Pays riches : écoles supérieures terminées légèrement plus par des femmes
- Pays à faibles revenus :
 écoles supérieures
 majoritairement terminées
 par des hommes

CONCLUSION

- Quelques informations à retenir :
- Pays à moyens revenus : beaucoup d'inscrits dans le Secondaire (dont privé) et Tertiaire
- Amérique du Nord : très connectée, mais peu d'inscrits dans le Secondaire.
- Asie (Est/Sud): beaucoup d'inscrits dans le Secondaire privé et Tertiaire, mais peu de redoublants dans le Secondaire.
- Chine et Inde: beaucoup d'enseignants et d'étudiants dans le Secondaire et Tertiaire
- **Programmes**: les plus sollicités dans le Tertiaire : Sciences Sociales / Economie / Droit. Le moins demandé : Agriculture.